Talent-Plan Section 2

宋阳

北京航空航天大学

Email: yangsoonlx@gmail.com

课程目标：熟悉分布式计算基础

1 课程作业

使用 Go 语言，使用框架代码，用 MapReduce + Shuffle 的方式完成作业: 从包含大量 URL 的数据文件中，求出现次数最多的前 10 个 URL 和他们的出现次数，尽量利用 CPU 多核特性和内存资源。根据作业框架完成作业，详细的作业要求、框架的使用方法和评分规则请看框架的 README 文件

2 课程报告

2.1 实验结果

下面分别展示 example 和自己编写的程序的执行结果，输出结果做了部分修剪

1. 因为电脑性能问题，执行 example 会超时，所以设置了超时时间。
2. 输出结果有些长，我就删除了一些 case 结果。

```
go test -v -run=TestExampleURLTop -timeout=20m
=== RUN TestExampleURLTop
Case0 PASS, dataSize=1MB, nMapFiles=5, cost=58.003091ms
Case4 PASS, dataSize=1MB, nMapFiles=5, cost=97.798085ms
Case0 PASS, dataSize=10MB, nMapFiles=10, cost=402.44546ms
Case4 PASS, dataSize=10MB, nMapFiles=10, cost=1.188909096s
Case0 PASS, dataSize=100MB, nMapFiles=20, cost=4.575127222s
Case4 PASS, dataSize=100MB, nMapFiles=20, cost=6.447491782s
Case0 PASS, dataSize=500MB, nMapFiles=40, cost=27.758063912s
Case4 PASS, dataSize=500MB, nMapFiles=40, cost=24.168485049s
Case0 PASS, dataSize=1GB, nMapFiles=60, cost=43.387110698s
Case4 PASS, dataSize=1GB, nMapFiles=60, cost=32.157396894s
--- PASS: TestExampleURLTop (647.35s)
PASS
ok   talent 648.721s
```

```
go test -v -run=TestURLTop -timeout=20m
=== RUN TestURLTop
Case0 PASS, dataSize=1MB, nMapFiles=5, cost=11.785912ms
Case4 PASS, dataSize=1MB, nMapFiles=5, cost=41.430071ms
Case0 PASS, dataSize=10MB, nMapFiles=10, cost=23.21466ms
Case4 PASS, dataSize=10MB, nMapFiles=10, cost=357.336826ms
Case0 PASS, dataSize=100MB, nMapFiles=20, cost=145.617177ms
Case4 PASS, dataSize=100MB, nMapFiles=20, cost=3.434310151s
Case0 PASS, dataSize=500MB, nMapFiles=40, cost=814.057602ms
Case4 PASS, dataSize=500MB, nMapFiles=40, cost=15.216412879s
Case0 PASS, dataSize=1GB, nMapFiles=60, cost=1.399076243s
Case4 PASS, dataSize=1GB, nMapFiles=60, cost=29.650313254s
--- PASS: TestURLTop (76.81s)
PASS
ok   talent 78.245s
```

2.2 实现和优化

任务一：补全 mapreduce.go 文件中的相应的代码。

MRCluster.worker 函数针对不同类型的任务做不同的处理，这个函数需要我们实现当任务为 reduce 类型的任务时需要进行的操作。reduce 任务可以分成 2 步：首先，reduce 任务收集属于同一个关键字的所有值，这里用 []string 存储一个键对应的所有值，用 $map[string][]string$ 来存储所有的键的信息。然后迭代 map 中的键值对，交由 reduceF 来对每个键的值集合进行处理并得出结果，并输出到相应的文件中。这部分的代码如下所示。

```
fw, bw := CreateFileAndBuf(mergeName(t.dataDir, t.jobName, t.taskNumber))
kvMap := make(map[string] []string)

for i:=0; i < t.nMap; i++ {
  rpath := reduceName(t.dataDir, t.jobName, i, t.taskNumber)
  file, err := os.Open(rpath)
  if err != nil {
    panic(err)
  }
  decoder := json.NewDecoder(file)
  for {
    var kv KeyValue
    err = decoder.Decode(&kv)
    if err != nil {
      break
    }
    if v, ok := kvMap[kv.Key]; ok{
      kvMap[kv.Key] = append(v, kv.Value)
    } else{
      kvMap[kv.Key] = []string{kv.Value}
    }
  }
  file.Close()
}

for key, value := range kvMap {
  res := t.reduceF(key, value)
  _, err := bw.Write([]byte(res))
```

```
  if err != nil {
   log.Fatal(err)
  }
 }
```

MRCluster.run 函数提取来自用户提交程序的配置信息来生成相应的 map 和 reduce 任务。我们要实现根据配置信息生成 reduce 任务，这部分很简单，关键在于每次任务可能分成了多个 MapReduce 任务，每次 MapReduce 任务执行之后需要将 reduce 生成的结果文件名传递给 notify 通道，告知下一次 map 任务需要读取的输入文件。

```
rtasks := make([]*task, 0, nReduce)
for i:=0; i < nReduce; i++ {
 t := &task{
  dataDir: dataDir,
  jobName: jobName,
  phase:   reducePhase,
  taskNumber: i,
  nReduce: nReduce,
  nMap:    nMap,
  reduceF: reduceF,
 }
 t.wg.Add(1)
 rtasks = append(rtasks, t)
 go func() { c.taskCh <- t }()
}

notifyFiles := make([]string, 0, nReduce)
for _,t := range rtasks {
 t.wg.Wait()
 fileName := mergeName(t.dataDir, t.jobName, t.taskNumber)
 notifyFiles = append(notifyFiles, fileName)
}
notify <- notifyFiles
```

任务二：实现你自己 MapF 和 ReduceF 来计算 top10。

example 代码分析

首先我们看一下 example 的实现，语言描述比较难以理解，可以直接看图2-1(为了简化流程，图中展示的是计算 top1 url 的执行过程)：如图所示，example 中的 topK 的计算分成了 2 次 MapReduce 来实现。

1. 第一轮，map 任务为每个 url 生成一个键值对，每个 map 任务将对 url 做 hash 处理，将 url 映射到不同的的 reduce 任务中，第一轮中的 reduce 任务统计每种 url 的出现次数，并输出结果。具体流程如下图的 round1 所示，第一轮 MapReduce 任务执行之后，会将产生的结果文件名发送到 notify 管道中，交由下一轮 map 任务读取。

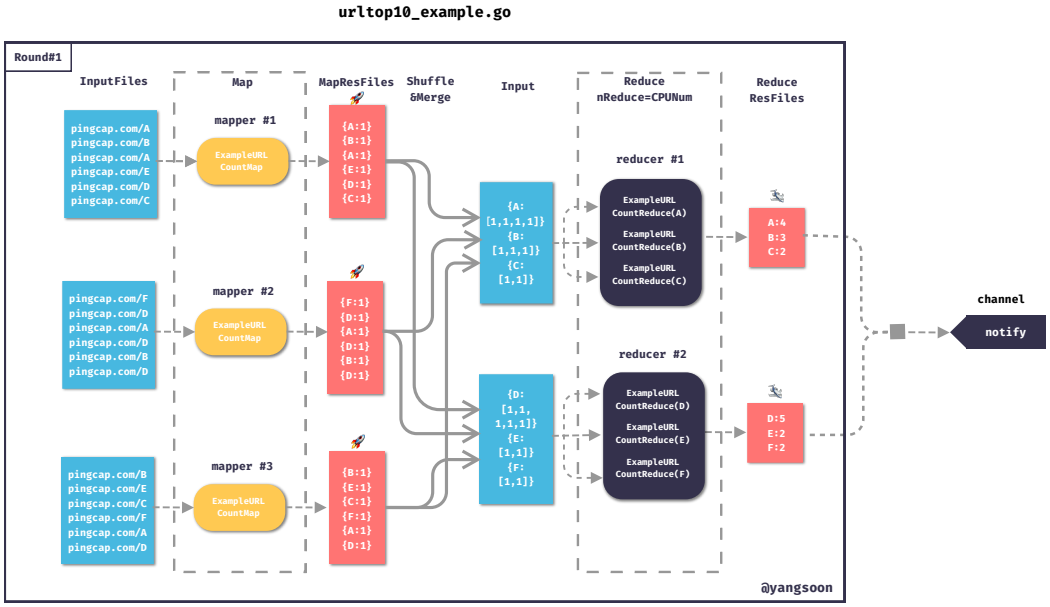

图 2-1 urltop10-example-round-1

2. 第二轮，map 任务从 notify 管道中读取需要处理的文件，这部分 map 任务就是简单的将每条数据做一个键值化，将每条 url 计数后的结果都分配给唯一的 reduce 任务，reduce 任务只处理一个键值对，其中 value 中存储了所有种类 url 的计算结果，接下来 reduce 任务计算出 topK，输出到唯一的一个结果文件中。具体的执行过程参考图2-2。

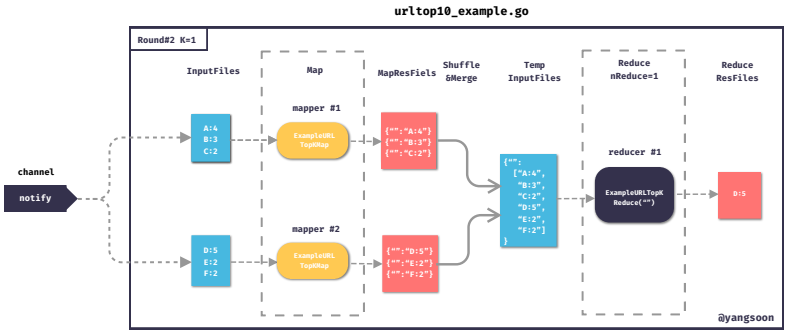

图 2-2 urltop10-example-round-2

2.2.1 第一次优化

当大概阅读完 example 的代码之后，我的第一感觉就是 example 代码有 2 处可以优化的部分：

1. 首先，在第 2 轮的 map 任务就可以提前计算每个 map 中的 top10 的 url，然后将结果发送给 reduce 任务处理，这样 reduce 任务的计算压力就会比较小了。

2. 因为只需要计算出 top10 即可，不需要对所有的 url 进行排序，计算 top10 的算法可以使用堆进行处理，维护一个有 10 个元素的小顶堆，这样也会减少对内存的申请，减少 gc 时间。

根据这样最初的想法，我实现了第一版的 urltop10，和 example 的代码一样，也是分成两轮，其中第一轮的代码直接复用 example 的代码，第二轮的 map 任务使用小顶堆来计算 top10，然后将结果发送给 reduce 任务，reduce 任务再对收集来的结果也使用小顶堆来计算 top10。

但是，最终的结果不是很理想，多次执行后，时间和 example 相差无几，时间在 630s 左右。下面是对程序的 cpu 性能分析结果。

```
go tool pprof cpu.prof
    Time: Oct 4, 2019 at 5:01pm (CST)
Duration: 10.55mins, Total samples = 24.77mins (234.68%)
Entering interactive mode (type "help" for commands, "o" for options)
(pprof) top
Type: cpu
Showing nodes accounting for 588.25s, 39.58% of 1486.06s total
Dropped 377 nodes (cum <= 7.43s)
Showing top 10 nodes out of 146
     flat flat% sum%     cum  cum%
  101.25s 6.81% 6.81% 114.77s 7.72% encoding/json.stateInString
   76.69s 5.16% 11.97% 164.62s 11.08% encoding/json.(*decodeState).scanWhile
   66.87s 4.50% 16.47% 189.21s 12.73% encoding/json.checkValid
   63.91s 4.30% 20.77% 63.91s 4.30% runtime.pthread_cond_signal
   62.79s 4.23% 25.00% 133.73s 9.00% runtime.scanobject
   58.89s 3.96% 28.96% 79.60s 5.36% runtime.findObject
   46.98s 3.16% 32.12% 183.71s 12.36% runtime.mallocgc
   44.32s 2.98% 35.11% 44.33s 2.98% encoding/json.unquoteBytes
   33.31s 2.24% 37.35% 94.69s 6.37% runtime.gcWriteBarrier
   33.24s 2.24% 39.58% 69.77s 4.69% runtime.mapassign_faststr
```

可以看到大部分时间都消耗在了 json 的解析和 gc 上，突然我意识到，性能瓶颈不在于排序计算，而是在于要降低 json 解析的压力，那么就需要尽量减少中间文件的大小。

2.2.2 第二次优化

继续看 example 代码，还能发现几个很明显的问题，首先每一轮的 map 任务都在做一些很简单的事情，只是对输入结果进行了一下简单的格式化。其次，第一轮的 reduce 任务每次只能在一组键值对上进行 reduce 操作，但是这时候 reduce 任务上已经有足够的信息来计算局部的 topk 来对中间结果进行压缩。

根据上面的分析，我进行了第二次的优化，抛弃之前的思路，具体的执行流程如下图所示，问题还是通过 2 轮 MapReduce 操作进行解决。

第一轮，map 任务对输入文件的 url 进行个数统计，计算每种 url 的出现次数，得到一个 url 和出现次数的结果然后在对结果格式化的时候进行一个特别的处理，和之前的处理不同，格式化的 key 不再是 url，而是 ihash(url)，就是经过 hash 之后的 url 值，value 存储着 url: count 形式的字符串，这样处理的原因是，这样处理的话 map 任务中将要发送到同一个 reduce work 的 url 都会有相同的 key，这样就能保证每个 reduce worker 经过 shuffle&merge 之后获得的输入信息是只有一个键值对的 map 对象，其中包括了所有发送到该 work 的 url 统计信息；reduce 任务获取到只有一个键值对的 map 对象后，首先 merge 相同 url 的执行次数，然后计算局部 topk，这样输出结果就只包含 K * nReduce 个信息。

可以对比下图和上图，在标有小火箭部分的文件，可以看到第一次中间文件的压缩结果，在标有小飞机部分的中间文件，有更加明显的数据压缩。

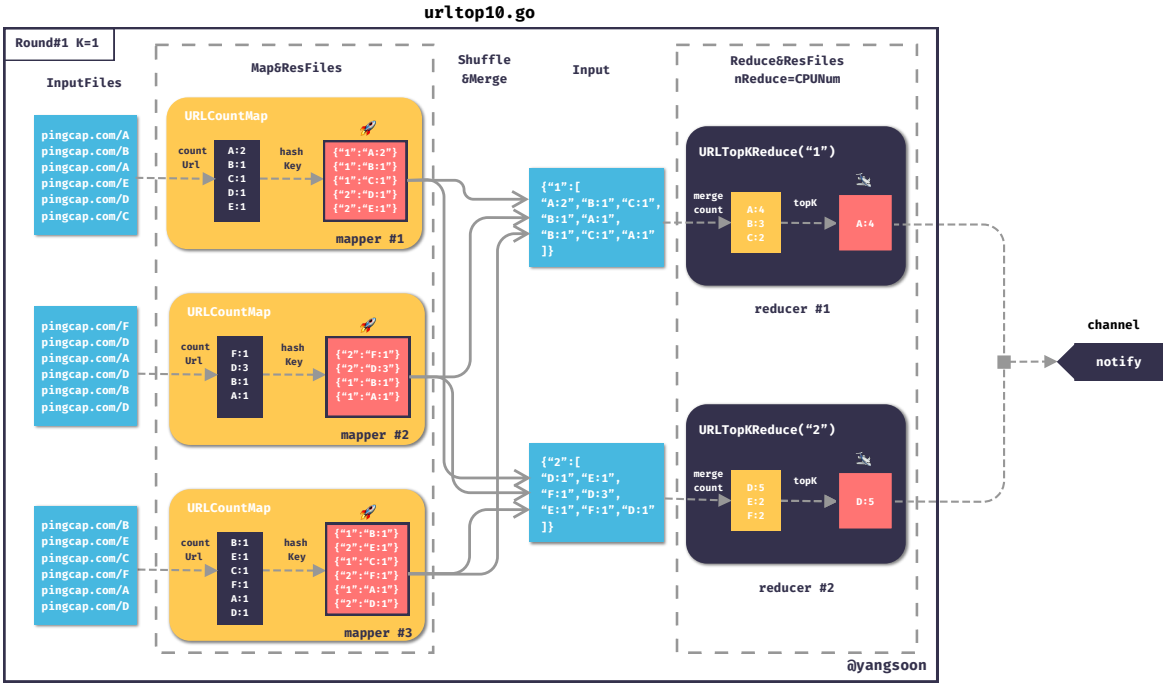

图 2-3 MapReduce

第二轮的操作和 example 的处理就一样了，这里就不做赘述。

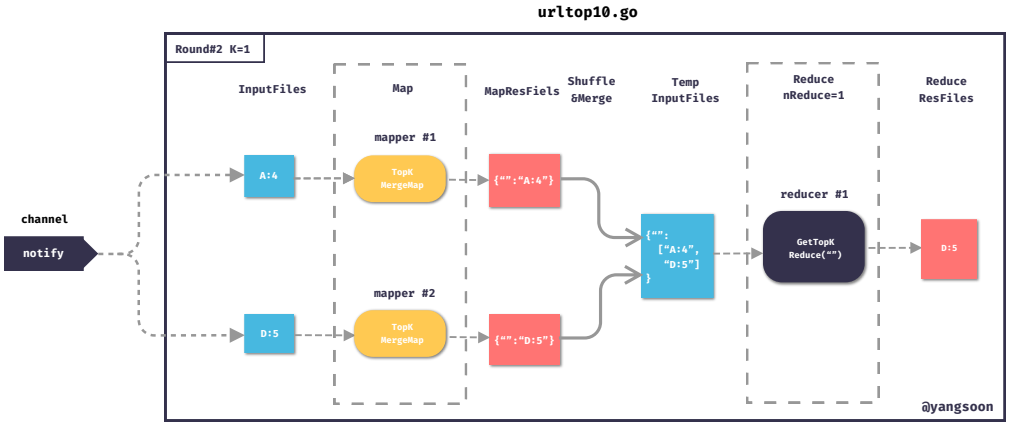

图 2-4 MapReduce

之前也考虑过只用一轮 MapReduce 解决问题，但是思考了一下，发现并不好，首先 map worker 的

处理逻辑就会比较复杂，而且只能开一个 reduce worker 会比较浪费 cpu 资源。实际上经过一轮的压缩，第二轮能够较快的执行完。实验显示第二轮的执行时间都在 1ms 左右。

部分代码因为主要在 first round 进行了优化了，所以只列出了 round1 的相关代码。

```
func URLTop10(nWorkers int) RoundsArgs {
  var args RoundsArgs

  args = append(args, RoundArgs{
    MapFunc: URLCountMap,
    ReduceFunc: URLCountReduce,
    NReduce: nWorkers,
  })

  args = append(args, RoundArgs{
    MapFunc: TopKMergeMap,
    ReduceFunc: GetTopKReduce,
    NReduce: 1,
  })

  return args
}

func URLCountMap(filename string, contents string) []KeyValue {
  lines := strings.Split(contents, "\n")
  kv := make(map[string]int, urlKind)
  for _, l := range lines {
    if len(l) == 0 {
      continue
    }
    kv[l] += 1
  }
  kvs := make([]KeyValue, 0, len(lines))
  var buffer bytes.Buffer
  for k, v := range kv {
    buffer.WriteString(k)
    buffer.WriteString("␣")
    buffer.WriteString(strconv.Itoa(v))

    kvs = append(kvs, KeyValue{
      Key: strconv.Itoa(ihash(k) % GetMRCluster().NWorkers()),
      Value: buffer.String(),
    })

    buffer.Reset()
  }
  return kvs
}

func URLCountReduce(key string, values []string) string {

  kv := make(map[string]int, urlKind)

  for _, value := range values {
    if len(value) == 0 {
      continue
    }
```

```
    tmp := strings.Split(value, "␣")
    n, err := strconv.Atoi(tmp[1])
    if err != nil {
      panic(err)
    }
    kv[tmp[0]] += n
  }

  topk := Top10(kv)

  buf := new(bytes.Buffer)
  for i := 0; i < len(topk); i++ {
    fmt.Fprintf(buf, "%s␣%d\n", topk[i].url, topk[i].cnt)
  }
  return buf.String()
}
```

2.3 性能分析

CPU cpu 性能分析的结果2-5上来看，syscall.syscall 调用耗费了大量的时间，从火焰图上能够看出是因为进行 json 解析文件产生的大量 IO 耗时。除了 syscall.syscall 之外几个函数都是和 gc 相关的函数调用。*runtime.mapassign_faststr* 执行时间过多，是因为在 URLCountMap 函数中计算每种 URL 的个数所以会频繁的查找 map，更新 map。strings.genSplit 是由于需要对传递给 URLCountMap 的数据根据换行符切片导致的大量时间消耗。

```
go tool pprof cpu.prof
Type: cpu
Time: Jan 4, 2020 at 9:31pm (CST)
Duration: 1.28mins, Total samples = 3.89mins (303.12%)
Entering interactive mode (type "help" for commands, "o" for options)
(pprof) top
Showing nodes accounting for 159.20s, 68.29% of 233.14s total
Dropped 295 nodes (cum <= 1.17s)
Showing top 10 nodes out of 133
      flat  flat%   sum%        cum   cum%
    93.42s 40.07% 40.07%     93.53s 40.12%  syscall.syscall
    12.22s  5.24% 45.31%     30.66s 13.15%  runtime.mapassign_faststr
     8.94s  3.83% 49.15%     18.70s  8.02%  runtime.scanobject
     7.88s  3.38% 52.53%      7.88s  3.38%  runtime.memmove
     7.07s  3.03% 55.56%      7.07s  3.03%  runtime.madvise
     6.98s  2.99% 58.55%      9.04s  3.88%  runtime.findObject
     6.95s  2.98% 61.53%      6.95s  2.98%  aeshashbody
     5.88s  2.52% 64.06%     23.07s  9.90%  strings.genSplit
     4.94s  2.12% 66.17%      4.94s  2.12%  memeqbody
     4.92s  2.11% 68.29%      4.92s  2.11%  runtime.memclrNoHeapPointers
```

图 2-5 CPU 火焰图

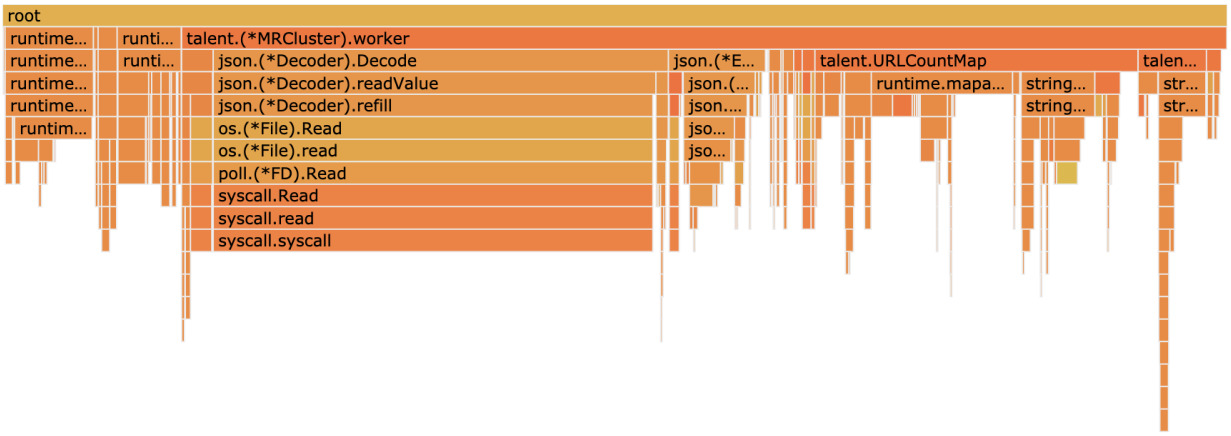

2.3.1 JSON 解析分析

因为官方自带的 json 解析器性能确实有待提升，所以就将官方的 json 解析器替换成 json-iterator，优化后的执行结果上来看确实有提升，但是和修改之前相比也就快了几秒的时间。

```
--- PASS: TestURLTop (76.81s)
PASS
ok   talent 78.245s

--- PASS: TestURLTop (72.64s)
PASS
ok   talent 74.104s
```

2.3.2 MEM 分析

从分析结果上来看，worker 和 URLCountMap 有较多的内存分配，其中 URLCountMap 是用户编写的代码，通过 list 命令查看 URLCountMap 函数发现是因为对 map 更新的时候 map 扩容导致的大量内存分配，因为 map 大小和数据中 URL 的种类有关，我就用一个 URLKind 的变量来表示初始化 map 的大小。这个变量和数据相关，就先这样处理，然后 strings.Split 函数导致的。通过图2-6能明显看到这几个函数执行时间耗费了较多的时间。最后还有一部分是因为自己实现代码的时候写出了 bug，也是通过 list 查看发现的，因为太蠢了就不列出来了。

```
go tool pprof mem.prof
Type: alloc_space
Time: Jan 4, 2020 at 9:32pm (CST)
Entering interactive mode (type "help" for commands, "o" for options)
(pprof) top
Showing nodes accounting for 100GB, 98.49% of 101.54GB total
Dropped 50 nodes (cum <= 0.51GB)
Showing top 10 nodes out of 25
      flat  flat%   sum%        cum   cum%
   25.67GB 25.28% 25.28% 25.67GB 25.28% github.com/json-iterator/go.NewStream
```

```
   22.61GB 22.27% 47.55% 101.53GB 100% talent.(*MRCluster).worker
   17.70GB 17.43% 64.98% 17.70GB 17.43% bytes.makeSlice
   10.87GB 10.71% 75.69% 23.80GB 23.44% talent.URLCountMap
   10.62GB 10.46% 86.15% 10.62GB 10.46% strings.genSplit
    6.23GB 6.14% 92.29% 6.23GB 6.14% bufio.NewWriterSize
    1.96GB 1.93% 94.22% 2.41GB 2.38% github.com/json-iterator/go.(*Iterator).ReadString
    1.88GB 1.85% 96.07% 2.56GB 2.52% talent.ihash
    1.78GB 1.75% 97.82% 1.78GB 1.75% bytes.(*Buffer).String
    0.68GB 0.67% 98.49% 0.68GB 0.67% hash/fnv.New32a
```

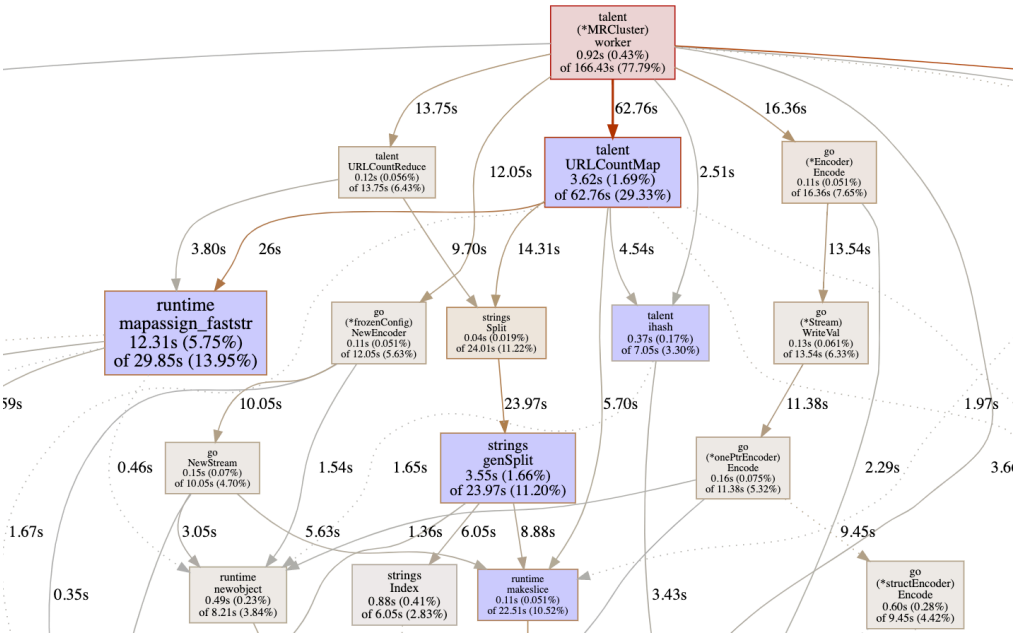

图 2-6 cpu-graph

go.NewStream 函数内存分配排到了第一，我们用 list 命令看一下具体的内存分配情况。从第 106 行可以看到，因为每次遍历 kvs 的时候都会初始化一遍 Encoder，实际上 Encoder 初始化 nReduce 次就足够了，这里可以修改一下，提前初始化 Encoder。因为这部分是框架上的代码，修改之后我会注释掉。

```
Type: alloc_space
Time: Jan 5, 2020 at 1:33pm (CST)
Entering interactive mode (type "help" for commands, "o" for options)
(pprof) list worker
Total: 101.54GB
ROUTINE ======================== talent.(*MRCluster).worker in /Users/yangs/Projects/talent-plan
    /tidb/mapreduce/mapreduce.go
  22.61GB 101.53GB (flat, cum) 100% of Total
       .       .    88: defer c.wg.Done()
       .       .    .....................
       .       .    98:         fs := make([]*os.File, t.nReduce)
       .       .    99:         bs := make([]*bufio.Writer, t.nReduce)
       .       .   100:         for i := range fs {
       .  512.03kB 101:            rpath := reduceName(t.dataDir, t.jobName, t.taskNumber, i)
       .    5.97GB 102:            fs[i], bs[i] = CreateFileAndBuf(rpath)
```

```
      .          .  103:         }
  17.69GB    41.49GB  104:         results := t.mapF(t.mapFile, string(content))
      .          .  105:         for _, kv := range results {
      .    26.64GB  106:            enc := json.NewEncoder(bs[ihash(kv.Key)%t.nReduce])
      .      350MB  107:            if err := enc.Encode(&kv); err != nil {
      .          .  108:               log.Fatalln(err)
      .          .  109:            }
      .          .  110:         }
```

经过优化后，我们可以看到 go.NewStream 已经不在 top10 了，而且 URLCountMap 的内存分配也降低了很多。

```
go tool pprof mem.prof
Type: alloc_space
Time: Jan 5, 2020 at 4:42pm (CST)
Entering interactive mode (type "help" for commands, "o" for options)
(pprof) top
Showing nodes accounting for 73.17GB, 98.11% of 74.58GB total
Dropped 56 nodes (cum <= 0.37GB)
Showing top 10 nodes out of 32
      flat  flat%   sum%      cum   cum%
   22.66GB 30.38% 30.38% 74.57GB  100% talent.(*MRCluster).worker
   17.69GB 23.72% 54.10% 17.69GB 23.72% bytes.makeSlice
   10.60GB 14.21% 68.31% 10.60GB 14.21% strings.genSplit
    6.25GB  8.38% 76.69%  6.25GB  8.38% bufio.NewWriterSize
    5.06GB  6.79% 83.48% 18.09GB 24.26% talent.URLCountMap
    4.48GB  6.01% 89.49%  4.48GB  6.01% github.com/json-iterator/go.(*Stream).
        WriteStringWithHTMLEscaped
    2.12GB  2.84% 92.33%  2.61GB  3.50% talent.ihash
    1.97GB  2.64% 94.97%  2.40GB  3.21% github.com/json-iterator/go.(*Iterator).ReadString
    1.85GB  2.48% 97.45%  1.85GB  2.48% bytes.(*Buffer).String
    0.49GB  0.66% 98.11%  0.49GB  0.66% hash/fnv.New32a
```

和初始版本相比执行时间快了几秒。

```
--- PASS: TestURLTop (76.81s)
PASS
ok   talent 78.245s
--- PASS: TestURLTop (68.05s)
PASS
ok   talent 68.792s
```